

**Definir la Base de Datos del Proyecto de empresa aliada**

Reckitt México, es una empresa líder en el mercado en productos de higiene del hogar, salud y nutrición, con marcas como Vanish, Lysol, Tempura, Sico, Durex y Chocomilk, entre muchas otras.

Hoy en día, una de las industrias con mayores aplicaciones de analítica de datos es la industria de Retail o Consumo Masivo. En este sector es común analizar grandes volúmenes de información para anticipar tendencias y desarrollar propuestas innovadoras que fortalezcan la venta al consumidor final. Todo esto permite diseñar mejores estrategias de mercadotecnia, presencia, precios y distribución, ayudando a incrementar las ventas frente a la competencia.

La información de una categoría específica menciona que: *"Cloros y blanqueadores de ropa, una de las más importantes para Reckitt gracias a la marca Vanish. Sin embargo, aún no somos lo suficientemente fuertes en todos los segmentos de la categoría (como blanqueadores en polvo, líquidos o en barra). Por ello, necesitamos identificar en qué segmentos estamos perdiendo presencia, quiénes son nuestros principales competidores y qué acciones podemos implementar para mejorar nuestro desempeño.*

*Además, dentro de esta categoría también contamos con Lysol Sanitizer, aunque todavía no tenemos claridad sobre si nuestra estrategia actual ha sido la más adecuada para ganar participación en el segmento de sanitizantes de ropa."*

## **INDICE**

### **Exploración y Limpieza del archivo CSV**

#### **Cargar y explorar el archivo de datos**

- **DIM CALENDAR**
- **DIM CATEGORY**
- **DIM SEGMENT**
- **DIM PRODUCT**
- **FACT SALES**

#### **Limpieza de datos**

- **DIM CALENDAR**
- **DIM CATEGORY**
- **DIM SEGMENT**
- **DIM PRODUCT**
- **FACT SALES**

### **Corrección del DataFrame "DIM CALENDAR"**

#### **Unir los DataFrames relevantes**

#### **Aplicar transformaciones necesarias**

#### **Guardar el archivo en formato CSV**

#### **Conclusiones**

1. Exploración y Limpieza del archivo CSV

- Correcciones en datos
- Limpieza de datos duplicados
- Rellenar espacios vacíos

1

| MANUFACTURER |             |            |               |           |             |             |                 |       |
|--------------|-------------|------------|---------------|-----------|-------------|-------------|-----------------|-------|
| A            | B           | C          | D             | E         | F           | G           | H               | I     |
| MANUFACTURER | BRAND       | ITEM       | ITEM_DESCR    | CATEGORY  | FORMAT      | ATTR1       | ATTR2           | ATTR3 |
| INDS. ALEN   | CLORALEX    | 75000592   | CLORALEX EI   | 1 LIQUIDO | COLORO      | COLORO      | NO DEFINIDO     |       |
| INDS. ALEN   | CLORALEX    | 75000608   | CLORALEX EI   | 1 LIQUIDO | COLORO      | COLORO      | NO DEFINIDO     |       |
| INDS. ALEN   | CLORALEX    | 75000615   | CLORALEX EI   | 1 LIQUIDO | COLORO      | COLORO      | NO DEFINIDO     |       |
| INDS. ALEN   | CLORALEX    | 75000622   | CLORALEX EI   | 1 LIQUIDO | COLORO      | COLORO      | NO DEFINIDO     |       |
| INDS. ALEN   | CLORALEX    | 75000639   | CLORALEX EI   | 1 LIQUIDO | COLORO      | COLORO      | NO DEFINIDO     |       |
| INDS. ALEN   | CLORALEX    | 75000646   | CLORALEX F/   | 1 LIQUIDO | COLORO      | COLORO      | OTR. TIPOS      |       |
| INDS. ALEN   | CLORALEX    | 75000653   | CLORALEX F/   | 1 LIQUIDO | COLORO      | COLORO      | OTR. TIPOS      |       |
| INDS. ALEN   | CLORALEX    | 75000677   | CLORALEX FF   | 1 LIQUIDO | COLORO      | COLORO      | NO DEFINIDO     |       |
| INDS. ALEN   | CLORALEX    | 75000684   | CLORALEX FF   | 1 LIQUIDO | COLORO      | COLORO      | NO DEFINIDO     |       |
| QUIMICA GO   | PATITO      | 75010539   | PATITO BOTE   | 1 LIQUIDO | COLORO      | COLORO      | OTR. TIPOS      |       |
| RECKITT      | LYSOL       | 1.9201E+10 | LYSOL SANITI  | 1 LIQUIDO | SANITIZANTE | SANITIZANTE | SANITIZANTE     |       |
| P&G          | TIDE        | 3.7E+10    | 9TIDE LIPIADI | 1 LIQUIDO | SAFE BLEACH | FABRIC TREA | PRE LAVADOR     |       |
| P&G          | TIDE        | 3.7E+10    | 9TIDE ADIVITI | 1 POLVO   | SAFE BLEACH | FABRIC TREA | OTR. TIPOS      |       |
| P&G          | TIDE        | 3.7001E+10 | 9TIDE BOOST   | 1 POLVO   | SAFE BLEACH | FABRIC TREA | OTR. TIPOS      |       |
| P&G          | TIDE        | 3.7001E+10 | TIDE MULTI P  | 1 POLVO   | SAFE BLEACH | FABRIC TREA | OTR. TIPOS      |       |
| OTHERS FABI  | OTHERS MAR  | 4.138E+10  | 9VALUE CLOI   | 1 LIQUIDO | COLORO      | COLORO      | OTR. TIPOS      |       |
| OTHERS FABI  | OTHERS MAR  | 4.138E+10  | SPECIAL VALI  | 1 LIQUIDO | COLORO      | COLORO      | OTR. TIPOS      |       |
| ARTIC WHITE  | ARTIC WHITE | 4.1596E+10 | 9ARCTIC WHI   | 1 LIQUIDO | COLORO      | COLORO      | OTR. TIPOS      |       |
| INDS. ALEN   | CLORALEX    | 4.3152E+10 | CLORALEX CI   | 1 LIQUIDO | SAFE BLEACH | FABRIC TREA | COLOR PODER VIN |       |
| CLOROX       | CLOROX      | 4.46E+10   | 9CLOROX RE    | 1 LIQUIDO | COLORO      | COLORO      | OTR. TIPOS      |       |

De los archivos a utilizar solo dos tuvieron notables correcciones y limpieza en algunos, a continuación, se explicará que fue lo que se realizo

Utilizando el archivo de “DIM\_PRODUCT” se comenzó a buscar y remplazar nombres y datos que estuvieran erróneos empezando desde la columna izquierda. Seguido de realizar eliminar datos duplicados y por último localizar celdas vacías para ser rellenas con “-”

2

| CATEGORY |              |             |             |         |                 |  |
|----------|--------------|-------------|-------------|---------|-----------------|--|
| A        | B            | C           | D           | E       | F               |  |
| CATEGORY | ATTR1        | ATTR2       | ATTR3       | FORMAT  | SEGMENT         |  |
| 1        | CLORO        | COLORO      | BAMBINO     | LIQUIDO | COLORO          |  |
| 2        | CLORO        | COLORO      | GERMICIDA   | LIQUIDO | COLORO          |  |
| 3        | CLORO        | COLORO      | MASCOTAS    | LIQUIDO | COLORO          |  |
| 4        | CLORO        | COLORO      | MULTIUSOS   | GEL     | COLORO          |  |
| 5        | CLORO        | COLORO      | MULTIUSOS   | LIQUIDO | COLORO          |  |
| 6        | CLORO        | COLORO      | NO DEFINIDC | LIQUIDO | COLORO          |  |
| 7        | CLORO        | COLORO      | NO DEFINIDC | POLVO   | COLORO          |  |
| 8        | CLORO        | COLORO      | OTR. TIPOS  | LIQUIDO | COLORO          |  |
| 9        | CLORO        | COLORO      | OTR. TIPOS  | POLVO   | COLORO          |  |
| 10       | CLORO        | COLORO      | ROPA BEBE   | LIQUIDO | COLORO          |  |
| 11       | CLORO        | COLORO      | NO DEFINIDC | LIQUIDO | COLORO          |  |
| 12       | CLORO        | MASCOTAS    | MASCOTAS    | LIQUIDO | COLORO          |  |
| 13       | CLORO        | MULTIUSOS   | MULTIUSOS   | GEL     | COLORO          |  |
| 14       | CLORO        | NO DEFINIDC | NO DEFINIDC | LIQUIDO | COLORO          |  |
| 15       | 1 PRE LAVADO | FABRIC TREA | BLANCO      | GEL     | LIQUIDO & GEL   |  |
| 16       | 1 PRE LAVADO | FABRIC TREA | BLANCO      | POLVO   | POLVO           |  |
| 17       | 1 PRE LAVADO | FABRIC TREA | BLANCO      | TOALLAS | OTROS           |  |
| 18       | 1 PRE LAVADO | FABRIC TREA | OTR. TIPOS  | LIQUIDO | PRE TRATAMIENTO |  |
| 19       | 1 PRE LAVADO | FABRIC TREA | PRE LAVADO  | LIQUIDO | PRE TRATAMIENTO |  |
| 20       | 1 PRE LAVADO | FABRIC TREA | PRE LAVADO  | POLVO   | POLVO           |  |

Como siguiente archivo a corregir es “DIM\_SEGMENT” donde no tuvo datos duplicados, pero se tuvieron que corregir muchos nombres que estaban con letras extras o erróneos. De igual manera no se contaron con muchas celdas vacías siendo una la que se tenia que rellenas con un “-”

2. Cargar y explorar el archivo de datos:

- Cargar el archivo.
- Explora el contenido con .head(), .info(), .describe() para entender la estructura.
- Identifica las variables clave.

1. Cargar y explorar el archivo de datos

```
[2]: import pandas as pd
calendar = pd.read_csv('DIM_CALENDAR.csv', encoding = 'ISO-8859-1')
calendar
```

|     | WEEK   | YEAR | MONTH | WEEK_NUMBER | DATE       |
|-----|--------|------|-------|-------------|------------|
| 0   | ene-21 | 2021 | 1     | 1           | 10/01/2021 |
| 1   | feb-21 | 2021 | 1     | 2           | 17/01/2021 |
| 2   | mar-21 | 2021 | 1     | 3           | 24/01/2021 |
| 3   | abr-21 | 2021 | 1     | 4           | 31/01/2021 |
| 4   | may-21 | 2021 | 2     | 5           | 07/02/2021 |
| ... | ...    | ...  | ...   | ...         | ...        |
| 151 | 48-23  | 2023 | 12    | 48          | 04/12/2023 |
| 152 | 49-23  | 2023 | 12    | 49          | 11/12/2023 |
| 153 | 50-23  | 2023 | 12    | 50          | 18/12/2023 |

Se cargaron los archivos con éxito utilizando **encoding = 'ISO-8859-1'** así como solamente utilizar la librería de Pandas

La ISO-8859-1, también conocida como Latin-1, es un estándar de codificación de caracteres ampliamente utilizado que permite representar textos en idiomas europeos occidentales, como el español, francés, alemán o portugués.

Fuente: (<https://factorial.es>)

```
[9]: category = pd.read_csv('DIM_CATEGORY.csv', encoding = 'ISO-8859-1')
category
```

| ID_CATEGORY | CATEGORY                           |
|-------------|------------------------------------|
| 0           | 1 FABRIC TREATMENT and SANITIZANTE |
| 1           | 2 AIR CARE                         |
| 2           | 3 LAVAVAJILLAS                     |
| 3           | 4 MEGA SUPERFICIES                 |
| 4           | 5 LAVATORY CARE & BRC              |

```
segment = pd.read_csv('DIM_SEGMENT.csv', encoding = 'ISO-8859-1')
segment
```

|   | CATEGORY | ATTR1 | ATTR2 | ATTR3       | FORMAT  | SEGMENT |
|---|----------|-------|-------|-------------|---------|---------|
| 0 | 1        | CLORO | CLORO | BAMBINO     | LIQUIDO | CLORO   |
| 1 | 1        | CLORO | CLORO | GERMICIDA   | LIQUIDO | CLORO   |
| 2 | 1        | CLORO | CLORO | MASCOTAS    | LIQUIDO | CLORO   |
| 3 | 1        | CLORO | CLORO | MULTIUSOS   | GEL     | CLORO   |
| 4 | 1        | CLORO | CLORO | MULTIUSOS   | LIQUIDO | CLORO   |
| 5 | 1        | CLORO | CLORO | NO DEFINIDO | LIQUIDO | CLORO   |
| 6 | 1        | CLORO | CLORO | NO DEFINIDO | POLVO   | CLORO   |
| 7 | 1        | CLORO | CLORO | OTR. TIPOS  | LIQUIDO | CLORO   |
| 8 | 1        | CLORO | CLORO | OTR. TIPOS  | POLVO   | CLORO   |

```
product = pd.read_csv('DIM_PRODUCT.csv', encoding = 'ISO-8859-1')
product
```

|     | MANUFACTURER | BRAND    | ITEM     | ITEM_DESCRIPTION                                  |
|-----|--------------|----------|----------|---------------------------------------------------|
| 0   | INDS. ALLEN  | CLORALEX | 75000592 | CLORALEX EL RENDIDOR BOT.PLAST. 250ML NAL. 000..  |
| 1   | INDS. ALLEN  | CLORALEX | 75000608 | CLORALEX EL RENDIDOR BOT.PLAST. 500ML NAL. 000..  |
| 2   | INDS. ALLEN  | CLORALEX | 75000615 | CLORALEX EL RENDIDOR BOT.PLAST. 950ML NAL. 000..  |
| 3   | INDS. ALLEN  | CLORALEX | 75000622 | CLORALEX EL RENDIDOR BOT.PLAST. 2000ML NAL. 000.. |
| 4   | INDS. ALLEN  | CLORALEX | 75000639 | CLORALEX EL RENDIDOR BOT.PLAST. 3750ML NAL. 000.. |
| ... | ...          | ...      | ...      | ...                                               |

Cada Data Frame fue resumido para que puedan ser visibles, en próximos pasos solo serán usados algunos para su respectiva exploración con comandos

```
sales = pd.read_csv('FACT_SALES.csv', encoding = 'ISO-8859-1')
sales
```

|   | WEEK  | ITEM_CODE        | TOTAL_UNIT_SALES | TOTAL_VALUE_SALES |
|---|-------|------------------|------------------|-------------------|
| 0 | 34-22 | 7501058792808BP2 | 0.006            | 0.139             |
| 1 | 34-22 | 7.50E+12         | 0.487            | 116.519           |
| 2 | 34-22 | 7.70E+12         | 1.391            | 68.453            |

**DIM CALENDAR - .head(), .describe(), .info()****DIM\_CALENDAR**

```
#Uso de .head() para exploracion del Data Frame
calendar.head()
```

|   | WEEK   | YEAR | MONTH | WEEK_NUMBER | DATE       |
|---|--------|------|-------|-------------|------------|
| 0 | ene-21 | 2021 |       | 1           | 10/01/2021 |
| 1 | feb-21 | 2021 | 1     | 2           | 17/01/2021 |
| 2 | mar-21 | 2021 | 1     | 3           | 24/01/2021 |
| 3 | abr-21 | 2021 | 1     | 4           | 31/01/2021 |
| 4 | may-21 | 2021 | 2     | 5           | 07/02/2021 |

```
#Uso de .describe() para exploracion del Data Frame
calendar.describe()
```

|       | YEAR        | MONTH      | WEEK_NUMBER |
|-------|-------------|------------|-------------|
| count | 156.000000  | 156.000000 | 156.000000  |
| mean  | 2022.000000 | 6.487179   | 26.500000   |
| std   | 0.819126    | 3.459419   | 15.056667   |
| min   | 2021.000000 | 1.000000   | 1.000000    |
| 25%   | 2021.000000 | 3.750000   | 13.750000   |
| 50%   | 2022.000000 | 6.500000   | 26.500000   |
| 75%   | 2023.000000 | 9.250000   | 39.250000   |
| max   | 2023.000000 | 12.000000  | 52.000000   |

```
#Uso de .info() para exploracion del Data Frame
calendar.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 156 entries, 0 to 155
Data columns (total 5 columns):
#   Column      Non-Null Count  Dtype
---  -
0    WEEK        156 non-null    object
1    YEAR        156 non-null    int64
2    MONTH       156 non-null    int64
3    WEEK_NUMBER 156 non-null    int64
4    DATE        156 non-null    object
dtypes: int64(3), object(2)
memory usage: 6.2+ KB
```

Con el uso del comando **.head()** se puede tener una muestra del *DataFrame* de los primeros resultados, siendo útil para siguientes pasos que será necesario para hacer algunas transformaciones en la columna de “*WEEK*”

El uso del comando **.describe()** durante la exploración de este *DataFrame* también es relevante ya que aporta a conocimiento sobre el numero de meses, años y semanas hay, tal como cuál es el mínimo y máximo de cada uno.

El uso del comando **.info()** permite saber cuántos datos incluye este *DataFrame* además de tener en cuenta que tipo de dato son, en su mayoría fue reconocido con éxito aun que de igual manera hay que especificarlo al momento de hacer limpieza en cada *DataFrame*

**DIM\_CATEGORY - .head(), .describe(), .info()****DIM\_CATEGORY**

*#Uso de .head() para exploracion del Data Frame*  
 category.head()

| ID_CATEGORY | CATEGORY                           |
|-------------|------------------------------------|
| 0           | 1 FABRIC TREATMENT and SANITIZANTE |
| 1           | 2 AIR CARE                         |
| 2           | 3 LAVAVAJILLAS                     |
| 3           | 4 MEGA SUPERFICIES                 |
| 4           | 5 LAVATORY CARE & BRC              |

*#Uso de .describe() para exploracion del Data Frame*  
 category.describe()

| ID_CATEGORY |          |
|-------------|----------|
| count       | 5.000000 |
| mean        | 3.000000 |
| std         | 1.581139 |
| min         | 1.000000 |
| 25%         | 2.000000 |
| 50%         | 3.000000 |
| 75%         | 4.000000 |
| max         | 5.000000 |

*#Uso de .info() para exploracion del Data Frame*  
 category.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 2 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   ID_CATEGORY  5 non-null      int64
1   CATEGORY     5 non-null      object
dtypes: int64(1), object(1)
memory usage: 212.0+ bytes
```

Con el uso del comando **.head()** no se detecto mucho cambio en su visualización de resultado, ya que al ser muy pocos datos solo mostraría los mismos

El uso del comando **.describe()** se pudo sacar un conteo, el mínimo y máximo de cada elemento dentro de la tabla, así como su media, aun que no aporte mucho como información relevante o de impacto

El uso del comando **.info()** se pudieron ubicar su respectivo tipo de dato lo que permitirá que a la hora de su manipulación sea fácil de integrar entre sí mismas

**DIM SEGMENT - .head(), .describe(), .info()**

```
#Uso de .head() para exploracion del Data Frame
segment.head()
```

|   | CATEGORY | ATTR1 | ATTR2 | ATTR3     | FORMAT  | SEGMENT |
|---|----------|-------|-------|-----------|---------|---------|
| 0 | 1        | CLORO | CLORO | BAMBINO   | LIQUIDO | CLORO   |
| 1 | 1        | CLORO | CLORO | GERMICIDA | LIQUIDO | CLORO   |
| 2 | 1        | CLORO | CLORO | MASCOTAS  | LIQUIDO | CLORO   |
| 3 | 1        | CLORO | CLORO | MULTIUSOS | GEL     | CLORO   |
| 4 | 1        | CLORO | CLORO | MULTIUSOS | LIQUIDO | CLORO   |

Con el uso del comando **.head()** se pudo obtener una muestra de los 5 primeros registros del *DataFrame*, en estos se puede observar que ninguno tiene algún error ortográfico o que pueda tener un elemento nulo

```
#Uso de .describe() para exploracion del Data Frame
segment.describe()
```

| CATEGORY |      |
|----------|------|
| count    | 53.0 |
| mean     | 1.0  |
| std      | 0.0  |
| min      | 1.0  |
| 25%      | 1.0  |
| 50%      | 1.0  |
| 75%      | 1.0  |
| max      | 1.0  |

El uso del comando **.describe()** aunque solo utilice una sola columna no contiene o adiciona alguna otra información más que solo otorgar el conteo de cuantos elementos están presentes en el *DataFrame*

```
#Uso de .info() para exploracion del Data Frame
segment.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 53 entries, 0 to 52
Data columns (total 6 columns):
#   Column      Non-Null Count  Dtype
---  -
0   CATEGORY    53 non-null    int64
1   ATTR1       53 non-null    object
2   ATTR2       53 non-null    object
3   ATTR3       53 non-null    object
4   FORMAT      53 non-null    object
5   SEGMENT     53 non-null    object
dtypes: int64(1), object(5)
memory usage: 2.6+ KB
```

El uso del comando **.info()** expuso el tipo de dato que presenta cada columna notando que todos cumplen con lo que se observa en el *DataFrame* por lo que no seria necesario señalar su tipo de dato en futuros pasos con la mayoría de columnas

**DIM PRODUCT - .head(), .describe(), .info()**

#Uso de .head() para exploracion del Data Frame  
product.head()



|   | MANUFACTURER | BRAND    | ITEM     | ITEM_DESCRIPTION                                            | CATEGORY | FORMAT  | ATTR1 | ATTR2 |
|---|--------------|----------|----------|-------------------------------------------------------------|----------|---------|-------|-------|
| 0 | INDS. ALEN   | CLORALEX | 75000592 | CLORALEX EL<br>RENDIDOR<br>BOT.PLAST. 250ML<br>NAL. 000...  | 1        | LIQUIDO | CLORO | CLORO |
| 1 | INDS. ALEN   | CLORALEX | 75000608 | CLORALEX EL<br>RENDIDOR<br>BOT.PLAST. 500ML<br>NAL. 000...  | 1        | LIQUIDO | CLORO | CLORO |
| 2 | INDS. ALEN   | CLORALEX | 75000615 | CLORALEX EL<br>RENDIDOR<br>BOT.PLAST. 950ML<br>NAL. 000...  | 1        | LIQUIDO | CLORO | CLORO |
| 3 | INDS. ALEN   | CLORALEX | 75000622 | CLORALEX EL<br>RENDIDOR<br>BOT.PLAST. 2000ML<br>NAL. 000... | 1        | LIQUIDO | CLORO | CLORO |
| 4 | INDS. ALEN   | CLORALEX | 75000639 | CLORALEX EL<br>RENDIDOR<br>BOT.PLAST. 3750ML<br>NAL. 000... | 1        | LIQUIDO | CLORO | CLORO |

Con el uso del comando **.head()** se expusieron los primeros 5 resultados, los cuales no se observan errores o elementos nulos que se necesiten corregir en pasos posteriores

#Uso de .describe() para exploracion del Data Frame  
product.describe()

| CATEGORY |       |
|----------|-------|
| count    | 505.0 |
| mean     | 1.0   |
| std      | 0.0   |
| min      | 1.0   |
| 25%      | 1.0   |
| 50%      | 1.0   |
| 75%      | 1.0   |
| max      | 1.0   |

El uso del comando **.describe()** muestra solamente el conteo dando el total de cada elemento puesto en el *DataFrame* sin tener mucha utilidad o adición a los siguientes datos registrados como su mínimo, máximo, porcentaje o promedio

#Uso de .info() para exploracion del Data Frame  
product.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 505 entries, 0 to 504
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  -
0   MANUFACTURER          505 non-null    object
1   BRAND                  505 non-null    object
2   ITEM                   505 non-null    object
3   ITEM_DESCRIPTION       505 non-null    object
4   CATEGORY               505 non-null    int64
5   FORMAT                 505 non-null    object
6   ATTR1                  505 non-null    object
7   ATTR2                  505 non-null    object
8   ATTR3                  505 non-null    object
dtypes: int64(1), object(8)
memory usage: 35.6+ KB
```

El uso del comando **.info()** ubico a cada elemento con su respectivo tipo de dato donde resalta una columna que a pesar que tiene números fue interpretado como objeto esto ocurrió porque dentro de la columna de *ITEM* existen elementos que contienen *LETRAS*

**FACT SALES- .head(), .describe(), .info()****FACT\_SALES**

```
#Uso de .head() para exploracion del Data Frame
sales.head()
```

|   | WEEK  | ITEM_CODE        | TOTAL_UNIT_SALES | TOTAL_VALUE_SALES | TOTAL_UNIT_AVG_WEEKLY_SALES |
|---|-------|------------------|------------------|-------------------|-----------------------------|
| 0 | 34-22 | 7501058792808BP2 | 0.006            | 0.139             | 1.000                       |
| 1 | 34-22 | 7.50E+12         | 0.487            | 116.519           | 2.916                       |
| 2 | 34-22 | 7.70E+12         | 1.391            | 68.453            | 5.171                       |
| 3 | 34-22 | 7.50E+12         | 0.022            | 1.481             | 1.833                       |
| 4 | 34-22 | 7.50E+12         | 2.037            | 182.839           | 5.375                       |

Con el uso del comando **.head()** expuso los primeros 5 resultados del *DataFrame* donde el que mas destaca es la columna de “*ITEM\_CODE*” por el tipo de elemento que maneja, esto se observa de esta forma por el numero de elementos que contiene la cifra

```
#Uso de .describe() para exploracion del Data Frame
sales.describe()
```

|       | TOTAL_UNIT_SALES | TOTAL_VALUE_SALES | TOTAL_UNIT_AVG_WEEKLY_SALES |
|-------|------------------|-------------------|-----------------------------|
| count | 122002.000000    | 122002.000000     | 122002.000000               |
| mean  | 3.211097         | 90.513761         | 10.099904                   |
| std   | 14.496009        | 350.236505        | 22.650142                   |
| min   | 0.000000         | 0.001000          | 0.042000                    |
| 25%   | 0.063000         | 2.662000          | 2.316000                    |
| 50%   | 0.367000         | 16.812000         | 3.993500                    |
| 75%   | 1.520000         | 62.961500         | 8.898000                    |
| max   | 504.681000       | 12236.759000      | 794.000000                  |

El uso del comando **.describe()** se sacó el conteo de todas las ventas, tal como su mínimo y máximo de ventas, mientras que al momento de obtener las promedio de dichas cifras todas tienen una diferencia de notable entre cada uno, mínimo de un 75% u 80%, ya que ya se habían calculado con anterioridad. Esto se considera como observación previa a su manipulación

```
#Uso de .info() para exploracion del Data Frame
sales.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 122002 entries, 0 to 122001
Data columns (total 6 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   WEEK                                  122002 non-null object
1   ITEM_CODE                             122002 non-null object
2   TOTAL_UNIT_SALES                      122002 non-null float64
3   TOTAL_VALUE_SALES                    122002 non-null float64
4   TOTAL_UNIT_AVG_WEEKLY_SALES          122002 non-null float64
5   REGION                               122002 non-null object
dtypes: float64(3), object(3)
memory usage: 5.6+ MB
```

El uso del comando **.info()** se ubican con éxito cada tipo de dato en su respectiva columna para en pasos posteriores establecerlas

### 3. Limpieza de datos:

- Corregir posibles inconsistencias en los datos, como errores tipográficos o formatos incorrectos.
- Identificar y maneja valores nulos en cada DataFrame (si es que los hay)
- Identificar si hay duplicados de los DataFrames y en caso de que los haya y eliminarlos.

#### DIM CALENDAR

```
#Verificacion de valores nulos
calendar.isna()
```

|     | WEEK  | YEAR  | MONTH | WEEK_NUMBER | DATE  |
|-----|-------|-------|-------|-------------|-------|
| 0   | False | False | False | False       | False |
| 1   | False | False | False | False       | False |
| 2   | False | False | False | False       | False |
| 3   | False | False | False | False       | False |
| 4   | False | False | False | False       | False |
| ... | ...   | ...   | ...   | ...         | ...   |
| 151 | False | False | False | False       | False |
| 152 | False | False | False | False       | False |
| 153 | False | False | False | False       | False |
| 154 | False | False | False | False       | False |
| 155 | False | False | False | False       | False |

El uso de los tres comandos para verificar si no hay elementos, variables o algun dato duplicado tuvo un resultado exitoso, ya que este no elimino algun dato sensible

```
calendar.isnull().sum()
```

```
WEEK      0
YEAR      0
MONTH     0
WEEK_NUMBER  0
DATE      0
dtype: int64
```

```
#Verificacion y eliminacion de datos duplicados
calendar.duplicated()
calendar.drop_duplicates()
```

|     | WEEK   | YEAR | MONTH | WEEK_NUMBER | DATE       |
|-----|--------|------|-------|-------------|------------|
| 0   | ene-21 | 2021 |       | 1           | 10/01/2021 |
| 1   | feb-21 | 2021 |       | 2           | 17/01/2021 |
| 2   | mar-21 | 2021 |       | 3           | 24/01/2021 |
| 3   | abr-21 | 2021 |       | 4           | 31/01/2021 |
| 4   | may-21 | 2021 |       | 5           | 07/02/2021 |
| ... | ...    | ...  | ...   | ...         | ...        |
| 151 | 48-23  | 2023 |       | 48          | 04/12/2023 |
| 152 | 49-23  | 2023 |       | 49          | 11/12/2023 |
| 153 | 50-23  | 2023 |       | 50          | 18/12/2023 |
| 154 | 51-23  | 2023 |       | 51          | 25/12/2023 |
| 155 | 52-23  | 2023 |       | 52          | 01/01/2024 |

```
#Aseguracion del tipo de dato en cada elemento
calendar['YEAR'].astype(int)
calendar['MONTH'].astype(int)
calendar['WEEK_NUMBER'].astype(int)
```

```
0      1
1      2
2      3
3      4
4      5
..
151    48
152    49
153    50
154    51
155    52
```

Como último paso de la limpieza de este *DataFrame* es asegurar los datos que se identificaron anteriormente. Dejando de lado los que eran objeto por defecto. Al tener dichos datos transformados a su tipo se tiene una previsualización de estos

**DIM CATEGORY**

```
#Verificacion de valores nulos
category.isna()
```

| ID_CATEGORY | CATEGORY |       |
|-------------|----------|-------|
| 0           | False    | False |
| 1           | False    | False |
| 2           | False    | False |
| 3           | False    | False |
| 4           | False    | False |

Dentro de este *DataFrame* no se encontraron datos, variables o elementos duplicados, incluso a simple vista se puede identificar esto, por lo que en el resultado del uso de los dos comandos dio como resultado lo mencionado

```
#Verificacion y eliminacion de datos duplicados
category.duplicated()
category.drop_duplicates()
```

| ID_CATEGORY | CATEGORY |                                  |
|-------------|----------|----------------------------------|
| 0           | 1        | FABRIC TREATMENT and SANITIZANTE |
| 1           | 2        | AIR CARE                         |
| 2           | 3        | LAVAVAJILLAS                     |
| 3           | 4        | MEGA SUPERFICIES                 |
| 4           | 5        | LAVATORY CARE & BRC              |

```
category.isnull().sum()
```

```
ID_CATEGORY    0
CATEGORY       0
dtype: int64
```

```
#Aseguracion del tipo de dato en cada elemento
category['ID_CATEGORY'].astype(int)
```

```
0    1
1    2
2    3
3    4
4    5
Name: ID_CATEGORY, dtype: int64
```

Dentro de este paso final con este *DataFrame* se utilizo una de las dos columnas para asignarle su respectivo tipo de dato, que aun que no sea relevante es parte de la limpieza que se tenga que cambiar el tipo de dato.

**DIM SEGMENT**

```
#Verificacion de valores nulos
segment.isna()
```

|   | CATEGORY | ATTR1 | ATTR2 | ATTR3 | FORMAT | SEGMENT |
|---|----------|-------|-------|-------|--------|---------|
| 0 | False    | False | False | False | False  | False   |
| 1 | False    | False | False | False | False  | False   |
| 2 | False    | False | False | False | False  | False   |
| 3 | False    | False | False | False | False  | False   |
| 4 | False    | False | False | False | False  | False   |
| 5 | False    | False | False | False | False  | False   |
| 6 | False    | False | False | False | False  | False   |
| 7 | False    | False | False | False | False  | False   |
| 8 | False    | False | False | False | False  | False   |

```
#Verificacion y eliminacion de datos duplicados
segment.duplicated()
segment.drop_duplicates()
```

|   | CATEGORY | ATTR1 | ATTR2 | ATTR3       | FORMAT  | SEGMENT |
|---|----------|-------|-------|-------------|---------|---------|
| 0 | 1        | CLORO | CLORO | BAMBINO     | LIQUIDO | CLORO   |
| 1 | 1        | CLORO | CLORO | GERMICIDA   | LIQUIDO | CLORO   |
| 2 | 1        | CLORO | CLORO | MASCOTAS    | LIQUIDO | CLORO   |
| 3 | 1        | CLORO | CLORO | MULTIUSOS   | GEL     | CLORO   |
| 4 | 1        | CLORO | CLORO | MULTIUSOS   | LIQUIDO | CLORO   |
| 5 | 1        | CLORO | CLORO | NO DEFINIDO | LIQUIDO | CLORO   |
| 6 | 1        | CLORO | CLORO | NO DEFINIDO | POLVO   | CLORO   |
| 7 | 1        | CLORO | CLORO | OTR. TIPOS  | LIQUIDO | CLORO   |
| 8 | 1        | CLORO | CLORO | OTR. TIPOS  | POLVO   | CLORO   |

Al utilizarse estos comandos sobre dichas variables del *DataFrame* dieron un resultado de que no hay ningún dato duplicado o que sea nulo. Esto se puede observar con el siguiente comando que señala esto

```
segment.isnull().sum()
```

```
CATEGORY    0
ATTR1        0
ATTR2        0
ATTR3        0
FORMAT       0
SEGMENT      0
```

```
#Aseguración del tipo de dato en cada elemento
segment['CATEGORY'].astype(int)
```

```
0      1
1      1
2      1
3      1
4      1
5      1
6      1
7      1
8      1
9      1
10     1
```

Que, aunque sea muy obvio y única la columna que lo requirió, se aseguró la asignación de tipo de dato para la manipulación de esta en los siguientes pasos del proceso

**DIM PRODUCT**

```
#Verificacion de valores nulos
product.isna()
```

|     | MANUFACTURER | BRAND | ITEM  | ITEM_DESCRIPTION | CATEGORY | FORMAT | ATTR1 | ATTR2 | ATTR3 |
|-----|--------------|-------|-------|------------------|----------|--------|-------|-------|-------|
| 0   |              | False | False | False            | False    | False  | False | False | False |
| 1   |              | False | False | False            | False    | False  | False | False | False |
| 2   |              | False | False | False            | False    | False  | False | False | False |
| 3   |              | False | False | False            | False    | False  | False | False | False |
| 4   |              | False | False | False            | False    | False  | False | False | False |
| ... | ...          | ...   | ...   | ...              | ...      | ...    | ...   | ...   | ...   |
| 500 |              | False | False | False            | False    | False  | False | False | False |
| 501 |              | False | False | False            | False    | False  | False | False | False |
| 502 |              | False | False | False            | False    | False  | False | False | False |

Desde la limpieza que se realizo principalmente en Excel se eliminaron datos duplicados, con faltas de ortografía o errores de escribir erróneamente el nombre, por lo que el resultado de los tres comandos dio un resultado exitoso al segundo chequeo y limpieza del *DataFrame*

```
#Verificacion y eliminacion de datos duplicados
product.duplicated()
product.drop_duplicates()
```

|     |            |          |                  |                                                   |     |         |             |                  |             |
|-----|------------|----------|------------------|---------------------------------------------------|-----|---------|-------------|------------------|-------------|
| ... | ...        | ...      | ...              | ...                                               | ... | ...     | ...         | ...              | ...         |
| 500 | RECKITT    | VANISH   | 7501058789778BP1 | VANISH EXT HIGIENE REM MANCHAS GAL 4LT + VANIS... | 1   | LIQUIDO | SAFE BLEACH | FABRIC TREATMENT | ROSA        |
| 501 | INDS, ALEN | CLORALEX | 7.50E+12         | CLORALEX AROMAS BLANQUEADOR C/AROMA LAVANDA GA... | 1   | LIQUIDO | CLORO       | CLORO            | NO DEFINIDO |
| 502 | INDS, ALEN | CLORALEX | -                | CLORALEX EL RENDIDOR BOT PLAST 2LT                | 1   | LIQUIDO | CLORO       | CLORO            | NO DEFINIDO |
| 503 | CLOROX     | CLOROX   | -                | CLOROX MASCOTAS BLANQUEADOR+DETERGENTE GALON 10L  | 1   | LIQUIDO | CLORO       | CLORO            | MASCOTAS    |
| 504 | CLOROX     | CLOROX   | 7502240948188BP1 | CLOROX BLANQ930M+MMBLANQINOD709M+MMFIBRAULTRA1... | 1   | LIQUIDO | CLORO       | CLORO            | NO DEFINIDO |

```
product.isnull().sum()
```

```
MANUFACTURER    0
BRAND            0
ITEM             0
ITEM_DESCRIPTION 0
CATEGORY         0
FORMAT           0
ATTR1            0
ATTR2            0
ATTR3            0
```

```
#Aseguración del tipo de dato en cada elemento
product['CATEGORY'].astype(int)
```

```
0      1
1      1
2      1
3      1
4      1
..
500    1
501    1
502    1
503    1
504    1
```

La columna que lo requirió, se aseguró la asignación de tipo de dato para la manipulación completa en los siguientes pasos del proceso

**FACT SALES**

```
#Verificacion de valores nulos
sales.isna()
```

|        | WEEK  | ITEM_CODE | TOTAL_UNIT_SALES | TOTAL_VALUE_SALES | TOTAL_UNIT_AVG_WEEKLY_SALES | REGION |
|--------|-------|-----------|------------------|-------------------|-----------------------------|--------|
| 0      | False | False     | False            | False             | False                       | False  |
| 1      | False | False     | False            | False             | False                       | False  |
| 2      | False | False     | False            | False             | False                       | False  |
| 3      | False | False     | False            | False             | False                       | False  |
| 4      | False | False     | False            | False             | False                       | False  |
| ...    | ...   | ...       | ...              | ...               | ...                         | ...    |
| 121997 | False | False     | False            | False             | False                       | False  |
| 121998 | False | False     | False            | False             | False                       | False  |
| 121999 | False | False     | False            | False             | False                       | False  |

```
#Verificacion y eliminacion de datos duplicados
sales.duplicated()
sales.drop_duplicates()
```

|        | WEEK  | ITEM_CODE        | TOTAL_UNIT_SALES | TOTAL_VALUE_SALES | TOTAL_UNIT_AVG_WEEKLY_SALES | REGION                      |
|--------|-------|------------------|------------------|-------------------|-----------------------------|-----------------------------|
| 0      | 34-22 | 7501058792808BP2 | 0.006            | 0.139             | 1.000                       | TOTAL AUTOS AREA 5          |
| 1      | 34-22 | 7.50E+12         | 0.487            | 116.519           | 2.916                       | TOTAL AUTOS AREA 5          |
| 2      | 34-22 | 7.70E+12         | 1.391            | 68.453            | 5.171                       | TOTAL AUTOS AREA 5          |
| 3      | 34-22 | 7.50E+12         | 0.022            | 1.481             | 1.833                       | TOTAL AUTOS AREA 5          |
| 4      | 34-22 | 7.50E+12         | 2.037            | 182.839           | 5.375                       | TOTAL AUTOS AREA 5          |
| ...    | ...   | ...              | ...              | ...               | ...                         | ...                         |
| 121997 | 26-23 | 7501058792778BP1 | 1.192            | 150.829           | 4.000                       | TOTAL AUTOS SCANNING MEXICO |
| 121998 | 26-23 | 7.50E+12         | 1.947            | 235.416           | 2.797                       | TOTAL AUTOS SCANNING MEXICO |
| 121999 | 26-23 | 7.50E+12         | 18.013           | 429.289           | 9.102                       | TOTAL AUTOS SCANNING MEXICO |

Dentro de este *DataFrame* no se encontraron duplicados ni tampoco faltas de ortografía o errores al escribir el nombre de cada elemento, por lo que el uso de los tres comandos para limpieza dio un resultado exitoso



```
sales.isnull().sum()
```

```
WEEK
ITEM_CODE
TOTAL_UNIT_SALES
TOTAL_VALUE_SALES
TOTAL_UNIT_AVG_WEEKLY_SALES
REGION
```

```
0
0
0
0
0
0
```

```
#Aseguración del tipo de dato en cada elemento
```

```
sales['TOTAL_UNIT_SALES'].astype(float)
sales['TOTAL_VALUE_SALES'].astype(float)
sales['TOTAL_UNIT_AVG_WEEKLY_SALES'].astype(float)
```

```
0      1.000
1      2.916
2      5.171
3      1.833
4      5.375
...
121997  4.000
121998  2.797
```



Aquí se utilizaron más columnas para la asignación y aseguración del tipo de dato, esta es transformación a tipo flotante para el siguiente paso del proceso

## 4. Correccion del DataFrame "DIM CALENDAR"

```
#Abrir el archivo que se busca corregir
import pandas as pd
df = pd.read_csv('DIM_CALENDAR.csv', encoding = 'ISO-8859-1' )
df
```

|     | WEEK   | YEAR | MONTH | WEEK_NUMBER | DATE       |
|-----|--------|------|-------|-------------|------------|
| 0   | ene-21 | 2021 | 1     | 1           | 10/01/2021 |
| 1   | feb-21 | 2021 | 1     | 2           | 17/01/2021 |
| 2   | mar-21 | 2021 | 1     | 3           | 24/01/2021 |
| 3   | abr-21 | 2021 | 1     | 4           | 31/01/2021 |
| 4   | may-21 | 2021 | 2     | 5           | 07/02/2021 |
| ... | ...    | ...  | ...   | ...         | ...        |
| 151 | 48-23  | 2023 | 12    | 48          | 04/12/2023 |
| 152 | 49-23  | 2023 | 12    | 49          | 11/12/2023 |
| 153 | 50-23  | 2023 | 12    | 50          | 18/12/2023 |
| 154 | 51-23  | 2023 | 12    | 51          | 25/12/2023 |
| 155 | 52-23  | 2023 | 1     | 52          | 01/01/2024 |

En otro archivo de tipo ".ipynb" se realizó la siguiente corrección, donde se identifico que una columna tenía datos erróneos que debían ser cambiados, esta columna es la de WEEK. Contenía datos de STR que no podían ser combinados con otra columna de otro *DataFrame* que se buscaba hacer un "merge"

```
#Correccion de La columna WEEK
def corregir_week(valor):
    try:
        meses = {
            'ene': 1, 'feb': 2, 'mar': 3, 'abr': 4,
            'may': 5, 'jun': 6, 'jul': 7, 'ago': 8,
            'sep': 9, 'oct': 10, 'nov': 11, 'dic': 12}

        if isinstance(valor, str) and '-' in valor:
            parte, year = valor.split('-')
            if parte.lower() in meses:
                mes = meses[parte.lower()]
            else:
                mes = int(parte)

            if 1 <= mes <= 12:
                return f'{mes:02d}-{year}'

        return valor

    except:
        return valor
```

```
df['WEEK'] = df.apply(
    lambda x: f'{int(x['WEEK_NUMBER']):02d}-{str(x['YEAR'])[-2:]}'
    if pd.notnull(x['WEEK_NUMBER']) and pd.notnull(x['YEAR'])
    else x['WEEK'],
    axis=1)
```

Se realizo el siguiente comando el cual fue definir una función combinado de utilizar un diccionario que apoyaría a la identificación de cada mes transformándolos a su respectivo número.

Con ello en próximos pasos se realizó otra función (esta vez Lambda) donde permite que los siguientes elementos de la misma columna no se hagan nulos

```
#Apliacion de la funcion sobre la columna a corregir
df['WEEK'] = df['WEEK'].apply(corregir_week)
df
```

|     | WEEK  | YEAR | MONTH | WEEK_NUMBER | DATE       |
|-----|-------|------|-------|-------------|------------|
| 0   | 01-21 | 2021 | 1     | 1           | 10/01/2021 |
| 1   | 02-21 | 2021 | 1     | 2           | 17/01/2021 |
| 2   | 03-21 | 2021 | 1     | 3           | 24/01/2021 |
| 3   | 04-21 | 2021 | 1     | 4           | 31/01/2021 |
| 4   | 05-21 | 2021 | 2     | 5           | 07/02/2021 |
| ... | ...   | ...  | ...   | ...         | ...        |
| 151 | 48-23 | 2023 | 12    | 48          | 04/12/2023 |
| 152 | 49-23 | 2023 | 12    | 49          | 11/12/2023 |
| 153 | 50-23 | 2023 | 12    | 50          | 18/12/2023 |
| 154 | 51-23 | 2023 | 12    | 51          | 25/12/2023 |
| 155 | 52-23 | 2023 | 1     | 52          | 01/01/2024 |

Donde los últimos pasos del proceso de corrección fue aplicar la función construida sobre la columna que se necesitaba modificar.

Por último, este fue guardado para su uso en el *DataFrame* original

```
#Guardar el nuevo archivo corregido
df.to_csv('DIM_WEEK(1).csv', index = False)
```

## 5. Unir los DataFrames relevantes:

- Realiza uniones entre los DataFrames para consolidar la información. Por ejemplo, une la tabla de productos con las ventas, las categorías y los segmentos.

Se puede observar que al realizar estas dos próximas uniones de *DataFrames* se realizara la creación de dos nuevas variantes a base de la extracción de datos de parte de los *DataFrames* originales *DIM\_PRODUCT*, *DIM\_CALENDAR* (corregido) y *FACT\_SALES* con el fin de saber cuales serian los principales competidores contra *RECKITT* y en que periodo de tiempo estas observaciones podrían dar una predicción adecuada a lo que ellos buscan

```
#Union de DataFrame(DIM_CALENDAR & FACT_SALES)
sales_week = pd.concat([sales,calendar], axis = 1)
sales_week
```

|        | WEEK  | ITEM_CODE        | TOTAL_UNIT_SALES | TOTAL_VALUE_SALES | TOTAL_UNIT_AVG_WEEKLY_SALES | REGION                      | WEEK  | YEAR   | MONTH | WEEK_NUMBER |
|--------|-------|------------------|------------------|-------------------|-----------------------------|-----------------------------|-------|--------|-------|-------------|
| 0      | 34-22 | 7501058792808BP2 | 0.006            | 0.139             | 1.000                       | TOTAL AUTOS AREA 5          | 01-21 | 2021.0 | 1.0   | 1.0 10/     |
| 1      | 34-22 | 7.50E+12         | 0.487            | 116.519           | 2.916                       | TOTAL AUTOS AREA 5          | 02-21 | 2021.0 | 1.0   | 2.0 17/     |
| 2      | 34-22 | 7.70E+12         | 1.391            | 68.453            | 5.171                       | TOTAL AUTOS AREA 5          | 03-21 | 2021.0 | 1.0   | 3.0 24/     |
| 3      | 34-22 | 7.50E+12         | 0.022            | 1.481             | 1.833                       | TOTAL AUTOS AREA 5          | 04-21 | 2021.0 | 1.0   | 4.0 31/     |
| 4      | 34-22 | 7.50E+12         | 2.037            | 182.839           | 5.375                       | TOTAL AUTOS AREA 5          | 05-21 | 2021.0 | 2.0   | 5.0 07/     |
| ...    | ...   | ...              | ...              | ...               | ...                         | ...                         | ...   | ...    | ...   | ...         |
| 121997 | 26-23 | 7501058792778BP1 | 1.192            | 150.829           | 4.000                       | TOTAL AUTOS SCANNING MEXICO | NaN   | NaN    | NaN   | NaN         |

Una observación de esta unión es que esta da información sobre como fueron las ventas en cuestión de tiempo, es decir se puede ver específicamente en que días y semanas se realizaron dichas ventas además de tener conocimiento de en qué región se realizaron dichas ventas

La siguiente unión que se realizo fue concatenar los *DataFrame* de producto y ventas, en esta nueva variante se observa que producto se vendió específicamente. Este nuevo *DataFrame* permite entender a profundidad además de lo previamente dicho señala en que región ocurrió dicha venta

```
prod_sale = pd.concat([product,sales], axis = 1)
prod_sale
```

|        | MANUFACTURER | BRAND    | ITEM     | ITEM_DESCRIPTION                                   | CATEGORY | FORMAT  | ATTR1  | ATTR2  | ATTR3       | WEEK  | ITEM_CODE        | TOTAL_UNIT_SALES |
|--------|--------------|----------|----------|----------------------------------------------------|----------|---------|--------|--------|-------------|-------|------------------|------------------|
| 0      | INDS. ALEN   | CLORALEX | 75000592 | CLORALEX EL RENDIDOR BOT.PLAST. 250ML NAL. 000...  | 1.0      | LIQUIDO | COLORO | COLORO | NO DEFINIDO | 34-22 | 7501058792808BP2 | 0.006            |
| 1      | INDS. ALEN   | CLORALEX | 75000608 | CLORALEX EL RENDIDOR BOT.PLAST. 500ML NAL. 000...  | 1.0      | LIQUIDO | COLORO | COLORO | NO DEFINIDO | 34-22 | 7.50E+12         | 0.487            |
| 2      | INDS. ALEN   | CLORALEX | 75000615 | CLORALEX EL RENDIDOR BOT.PLAST. 950ML NAL. 000...  | 1.0      | LIQUIDO | COLORO | COLORO | NO DEFINIDO | 34-22 | 7.70E+12         | 1.391            |
| 3      | INDS. ALEN   | CLORALEX | 75000622 | CLORALEX EL RENDIDOR BOT.PLAST. 2000ML NAL. 000... | 1.0      | LIQUIDO | COLORO | COLORO | NO DEFINIDO | 34-22 | 7.50E+12         | 0.022            |
| 4      | INDS. ALEN   | CLORALEX | 75000639 | CLORALEX EL RENDIDOR BOT.PLAST. 3750ML NAL. 000... | 1.0      | LIQUIDO | COLORO | COLORO | NO DEFINIDO | 34-22 | 7.50E+12         | 2.037            |
| ...    | ...          | ...      | ...      | ...                                                | ...      | ...     | ...    | ...    | ...         | ...   | ...              | ...              |
| 121997 | NaN          | NaN      | NaN      | NaN                                                | NaN      | NaN     | NaN    | NaN    | NaN         | 26-23 | 7501058792778BP1 | 1.192            |

Ambos *DataFrames* como resultado tuvieron muchos elementos que cambiaron su tipo de dato o incluso generara datos nulos, por lo que a estos dos se les realizara una limpieza y transformación en los siguientes pasos para finalmente dar observaciones a profundidad y mejor explicación sobre insights que se obtuvieron

## 6. Aplicar transformaciones necesarias

- Estandariza los formatos de las columnas, como las fechas o categorías, para asegurar la consistencia en todo el conjunto de datos.
- Realiza cualquier transformación adicional requerida para preparar los datos para el análisis, como la creación de nuevas columnas calculadas o la agrupación de datos.

```
#Limpieza del DataFrame eliminando duplicados y transformacion de tipo de datos
sales_week = sales_week.dropna()
sales_week = sales_week.drop_duplicates()
sales_week['MONTH'] = sales_week['MONTH'].astype(int)
sales_week['WEEK_NUMBER'] = sales_week['WEEK_NUMBER'].astype(int)
sales_week['YEAR'] = sales_week['YEAR'].astype(int)

sales_week
```

|   | WEEK  | ITEM_CODE        | TOTAL_UNIT_SALES | TOTAL_VALUE_SALES | TOTAL_UNIT_AVG_WEEKLY_SALES | REGION             | WEEK  | YEAR | MONTH | WEEK_NUMBER |            |
|---|-------|------------------|------------------|-------------------|-----------------------------|--------------------|-------|------|-------|-------------|------------|
| 0 | 34-22 | 7501058792808BP2 | 0.006            | 0.139             | 1.000                       | TOTAL AUTOS AREA 5 | 01-21 | 2021 | 1     | 1           | 10/01/2021 |
| 1 | 34-22 | 7.50E+12         | 0.487            | 116.519           | 2.916                       | TOTAL AUTOS AREA 5 | 02-21 | 2021 | 1     | 2           | 17/01/2021 |
| 2 | 34-22 | 7.70E+12         | 1.391            | 68.453            | 5.171                       | TOTAL AUTOS AREA 5 | 03-21 | 2021 | 1     | 3           | 24/01/2021 |
| 3 | 34-22 | 7.50E+12         | 0.022            | 1.481             | 1.833                       | TOTAL AUTOS AREA 5 | 04-21 | 2021 | 1     | 4           | 31/01/2021 |
|   |       |                  |                  |                   |                             | TOTAL              |       |      |       |             |            |



La transformación principal que se realizó a este DataFrame fue una limpieza debido a que este presentaba datos innecesarios y poco relevantes o que no podrían aportar suficiente al análisis final de esta sección, por lo que de igual manera para que en el siguiente paso del proceso se realizaran ciertas transformaciones que permitirán tener un nuevo DataFrame completo

```
[58]: #Estandarización de datos de la columna ITEM_CODE
sales_week['ITEM_CODE'] = sales_week['ITEM_CODE'].astype(str)
sales_week['ITEM_CODE'] = sales_week['ITEM_CODE'].apply(lambda x: format(float(x), '.0f') if 'E+' in str(x) else x)
sales_week
```

|   | WEEK  | ITEM_CODE        | TOTAL_UNIT_SALES | TOTAL_VALUE_SALES | TOTAL_UNIT_AVG_WEEKLY_SALES | REGION             | WEEK  | YEAR | MONTH | WEEK_NUMBER |            |
|---|-------|------------------|------------------|-------------------|-----------------------------|--------------------|-------|------|-------|-------------|------------|
| 0 | 34-22 | 7501058792808BP2 | 0.006            | 0.139             | 1.000                       | TOTAL AUTOS AREA 5 | 01-21 | 2021 | 1     | 1           | 10/01/2021 |
| 1 | 34-22 | 7500000000000    | 0.487            | 116.519           | 2.916                       | TOTAL AUTOS AREA 5 | 02-21 | 2021 | 1     | 2           | 17/01/2021 |
| 2 | 34-22 | 7700000000000    | 1.391            | 68.453            | 5.171                       | TOTAL AUTOS AREA 5 | 03-21 | 2021 | 1     | 3           | 24/01/2021 |
| 3 | 34-22 | 7500000000000    | 0.022            | 1.481             | 1.833                       | TOTAL AUTOS AREA 5 | 04-21 | 2021 | 1     | 4           | 31/01/2021 |
|   |       |                  |                  |                   |                             | TOTAL              |       |      |       |             |            |

Como siguiente paso de su transformación se realizó una estandarización dentro de la columna de "ITEM\_CODE" donde sus elementos principalmente asignaron como tipo de dato cadena, permitiendo que se obtenga una transformación de datos con el uso de la función **lambda**, con ello obtener un resultado exitoso que permitirá en los siguientes pasos del proceso una mejor manipulación de este *DataFrame*

En el siguiente *DataFrame* se realizará una limpieza que permitirá tener los datos relevantes para su siguiente análisis, para en ello transformar dos columnas que permitirán que en el siguiente paso hacer su respectiva estandarización, así como de igual manera asignarle o añadirle alguna columna que permita calcular alguna de las columnas presentes

#limpieza del DataFrame eliminando duplicados y transformacion de tipos de datos

prod\_sale = prod\_sale.dropna()  
prod\_sale = prod\_sale.drop\_duplicates()  
prod\_sale['CATEGORY'] = prod\_sale['CATEGORY'].astype(int)  
prod\_sale['ITEM\_CODE'] = prod\_sale['ITEM\_CODE'].astype(str)

prod\_sale

| ND   | ITEM             | ITEM_DESCRIPTION                                   | CATEGORY | FORMAT  | ATTR1       | ATTR2            | ATTR3       | WEEK   | ITEM_CODE        |
|------|------------------|----------------------------------------------------|----------|---------|-------------|------------------|-------------|--------|------------------|
| LEX  | 75000592         | CLORALEX EL RENDIDOR BOT.PLAST. 250ML NAL. 000...  | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22  | 7501058792808BP2 |
| LEX  | 75000608         | CLORALEX EL RENDIDOR BOT.PLAST. 500ML NAL. 000...  | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22  | 7.50E+12         |
| LEX  | 75000615         | CLORALEX EL RENDIDOR BOT.PLAST. 950ML NAL. 000...  | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22  | 7.70E+12         |
| LEX  | 75000622         | CLORALEX EL RENDIDOR BOT.PLAST. 2000ML NAL. 000... | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22  | 7.50E+12         |
| LEX  | 75000639         | CLORALEX EL RENDIDOR BOT.PLAST. 3750ML NAL. 000... | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22  | 7.50E+12         |
| ...  | ...              | ...                                                | ...      | ...     | ...         | ...              | ...         | ...    | ...              |
| IISH | 7501058789778BP1 | VANISH EXT HIGIENE REM MANCHAS GAL 4LT + VANIS...  | 1        | LIQUIDO | SAFE BLEACH | FABRIC TREATMENT | ROSA        | jun-22 | 7.50E+12         |
| LEX  | 7.50E+12         | CLORALEX AROMAS BLANQUEADOR C/AROMA LAVANDA GA...  | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | jun-22 | 7.50E+12         |
| LEX  | -                | CLORALEX EL RENDIDOR BOT PLAST 2LT                 | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | jun-22 | 7501681100650BP1 |
| ROX  | -                | CLOROX MASCOTAS BLANQUEADOR+DETERGENTE GALON 10L   | 1        | LIQUIDO | COLORO      | COLORO           | MASCOTAS    | jun-22 | 7.50E+12         |

#Estandarizacion de la columna WEEK

meses = {'ene': '01', 'feb': '02', 'mar': '03', 'abr': '04', 'may': '05', 'jun': '06', 'jul': '07', 'ago': '08', 'sep': '09', 'oct': '10', 'nov': '11', 'dic': '12'}  
def convertir\_mes(valor):  
 if isinstance(valor, str) and '-' in valor:  
 parte1, parte2 = valor.split('-')  
 parte1 = parte1.lower().strip()  
  
 if parte1 in meses:  
 return f"{meses[parte1]}-{parte2}"  
  
 return valor  
prod\_sale['WEEK'] = prod\_sale['WEEK'].apply(convertir\_mes)  
prod\_sale

| ITEM_DESCRIPTION                               | CATEGORY | FORMAT  | ATTR1       | ATTR2            | ATTR3       | WEEK     |
|------------------------------------------------|----------|---------|-------------|------------------|-------------|----------|
| EL RENDIDOR BOT.PLAST. 250ML NAL. 000...       | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22 75 |
| EL RENDIDOR BOT.PLAST. 500ML NAL. 000...       | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22    |
| EL RENDIDOR BOT.PLAST. 950ML NAL. 000...       | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22    |
| L RENDIDOR BOT.PLAST. 2000ML NAL. 000...       | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22    |
| L RENDIDOR BOT.PLAST. 3750ML NAL. 000...       | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22    |
| ...                                            | ...      | ...     | ...         | ...              | ...         | ...      |
| HIGIENE REM MANCHAS GAL 4LT + VANIS...         | 1        | LIQUIDO | SAFE BLEACH | FABRIC TREATMENT | ROSA        | 06-22    |
| RALEX AROMAS BLANQUEADOR C/AROMA LAVANDA GA... | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 06-22    |
| CLORALEX EL RENDIDOR BOT PLAST 2LT             | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 06-22 75 |
| C MASCOTAS BLANQUEADOR+DETERGENTE GALON 10L    | 1        | LIQUIDO | COLORO      | COLORO           | MASCOTAS    | 06-22    |
| CLOROX +MMBLANQINOD709M+MMFIBRAULTRA1...       | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 06-22    |

Para su estandarización lo que se realizó es un diccionario donde permita cambiar uno de los errores que fue que pandas automáticamente mostrara las fechas con nombre del mes. Para en ello definir una función donde devuelva dichos meses en su respectivo numero Finalmente esta se aplica y se obtiene la columna de WEEK corregida para su siguiente manipulación de datos

Como último paso de estandarización para este *DataFrame* se aplicó una función de **lambda** para el cambio de tipo de dato científico sobre las columnas de ITEM y *ITEM\_CODE*. Estos pasos se aplican sobre dichos *DataFrames* para su próxima unión permitiendo un *DataFrame* completo que pueda tener columnas calculadas

```
# Union y limpieza de DataFrames unidos
prod_sale_week = pd.concat([prod_sale, sales_week], axis = 1)
prod_sale_week = prod_sale_week.fillna(0)
prod_sale_week = prod_sale_week.loc[:, ~prod_sale_week.columns.duplicated() ]
prod_sale_week['YEAR'] = prod_sale_week['YEAR'].astype(int)
prod_sale_week['MONTH'] = prod_sale_week['MONTH'].astype(int)
prod_sale_week['WEEK_NUMBER'] = prod_sale_week['WEEK_NUMBER'].astype(int)
prod_sale_week
```

| MANUFACTURER | BRAND    | ITEM             | ITEM_DESCRIPTION                                   | CATEGORY | FORMAT  | ATTR1       | ATTR2            | ATTR3       | WEEK  |
|--------------|----------|------------------|----------------------------------------------------|----------|---------|-------------|------------------|-------------|-------|
| INDS. ALEN   | CLORALEX | 75000592         | CLORALEX EL RENDIDOR BOT.PLAST. 250ML NAL. 000...  | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22 |
| INDS. ALEN   | CLORALEX | 75000608         | CLORALEX EL RENDIDOR BOT.PLAST. 500ML NAL. 000...  | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22 |
| INDS. ALEN   | CLORALEX | 75000615         | CLORALEX EL RENDIDOR BOT.PLAST. 950ML NAL. 000...  | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22 |
| INDS. ALEN   | CLORALEX | 75000622         | CLORALEX EL RENDIDOR BOT.PLAST. 2000ML NAL. 000... | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22 |
| INDS. ALEN   | CLORALEX | 75000639         | CLORALEX EL RENDIDOR BOT.PLAST. 3750ML NAL. 000... | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 34-22 |
| RECKITT      | VANISH   | 75010587897788P1 | VANISH EXT HIGIENE REM MANCHAS GAL 4LT + VANIS...  | 1        | LIQUIDO | SAFE BLEACH | FABRIC TREATMENT | ROSA        | 06-22 |
| INDS. ALEN   | CLORALEX | 7500000000000    | CLORALEX AROMAS BLANQUEADOR C/AROMA LAVANDA GAL... | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 06-22 |
| INDS. ALEN   | CLORALEX | -                | CLORALEX EL RENDIDOR BOT PLAST 2LT                 | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 06-22 |
| CLOROX       | CLOROX   | -                | CLOROX MASCOTAS BLANQUEADOR+DETERGENTE GALON 10L   | 1        | LIQUIDO | COLORO      | COLORO           | MASCOTAS    | 06-22 |
| CLOROX       | CLOROX   | 75022409481888P1 | CLOROX BLANQ930M+MMBLANQIN00709M+MMFIBRAULTRA1...  | 1        | LIQUIDO | COLORO      | COLORO           | NO DEFINIDO | 06-22 |

Al unir ambos *DataFrames* se realiza una limpieza de eliminar duplicados y rellenar los elementos nulos a “0”, además de establecer todo dato a su respectivo tipo para que en su momento de agrupación no tenga problema

Como siguiente paso del proceso se agruparon los datos, así como se agregaron columnas calculadas que permitieron tener una visibilidad completa sobre cada artículo, semana y en que región se realizo dicha venta

```
final_prod = prod_sale_week.groupby(['ITEM', 'BRAND', 'WEEK', 'ATTR1', 'REGION']).agg({'TOTAL_UNIT_SALES': ['sum', 'median', 'std'], 'TOTAL_VALUE_SALES': 'sum', 'TOTAL_UNIT_AVG_WEEKLY_SALES': 'mean'}).reset_index()

final_prod = final_prod.fillna(0)
final_prod
```

|     | ITEM             | BRAND       | WEEK  | ATTR1       | REGION                      | TOTAL_UNIT_SALES | TOTAL_VALUE_SALES | TOTAL_UNIT_AVG_WEEKLY_SALES |         |           |
|-----|------------------|-------------|-------|-------------|-----------------------------|------------------|-------------------|-----------------------------|---------|-----------|
|     |                  |             |       |             |                             | sum              | median            | std                         | sum     | mean      |
| 0   | -                | CLORALEX    | 06-22 | COLORO      | TOTAL AUTOS AREA 2          | 0.435            | 0.435             | 0.000000                    | 5.788   | 9.255000  |
| 1   | -                | CLOROX      | 06-22 | COLORO      | TOTAL AUTOS AREA 2          | 1.097            | 1.097             | 0.000000                    | 16.307  | 14.064000 |
| 2   | 07570375140168P1 | OXI CLEAN   | 05-22 | SAFE BLEACH | TOTAL AUTOS SCANNING MEXICO | 0.460            | 0.460             | 0.000000                    | 10.209  | 3.194000  |
| 3   | 1230000000000    | CLORALEX    | 34-22 | COLORO      | TOTAL AUTOS AREA 6          | 0.072            | 0.072             | 0.000000                    | 18.880  | 1.309000  |
| 4   | 19200958714      | LYSOL       | 34-22 | SANITIZANTE | TOTAL AUTOS AREA 5          | 2.188            | 2.188             | 0.000000                    | 23.792  | 17.934000 |
| ... | ...              | ...         | ...   | ...         | ...                         | ...              | ...               | ...                         | ...     | ...       |
| 164 | 7890000000000    | VANISH      | 06-22 | SAFE BLEACH | TOTAL AUTOS AREA 2          | 0.504            | 0.252             | 0.239002                    | 11.739  | 3.355500  |
| 165 | 79893431208      | WHITE MAGIC | 34-22 | NO DEFINIDO | TOTAL AUTOS AREA 6          | 0.001            | 0.001             | 0.000000                    | 0.042   | 1.000000  |
| 166 | 8410000000000    | IBERIA      | 06-22 | COLORO      | TOTAL AUTOS AREA 2          | 0.679            | 0.679             | 0.000000                    | 27.927  | 2.219000  |
| 167 | 8410000000000    | IBERIA      | 06-22 | NO DEFINIDO | TOTAL AUTOS AREA 2          | 0.192            | 0.192             | 0.000000                    | 4.728   | 2.313000  |
| 168 | 8410000000000    | IBERIA      | 06-22 | SAFE BLEACH | TOTAL AUTOS AREA 2          | 35.389           | 8.574             | 7.587335                    | 611.070 | 20.641667 |

## 7. Guardar el archivo en formato CSV

- Guarda el DataFrame consolidado en un nuevo archivo CSV o Excel para su uso posterior en el análisis.

## 5. Guardar el archivo

```
#Guardar el DataFrame Final
final_prod.to_csv("FINAL_PROD.csv")
```

Como ultimo paso del proceso se guarda el archivo para su próximo uso donde permitirá ver el grafico que se llevara a cabo

Se verifica que se haya guardado correctamente dicho archivo abriendo Excel

|    | A                | B    | C           | D      | E           | F           | G           | H           | I           | J          | K              |  |
|----|------------------|------|-------------|--------|-------------|-------------|-------------|-------------|-------------|------------|----------------|--|
|    |                  | ITEM | BRAND       | WEEK   | ATTR1       | REGION      | TOTAL_UNIT_ | TOTAL_UNIT_ | TOTAL_UNIT_ | TOTAL_VALU | TOTAL_UNIT_AVG |  |
|    |                  |      |             |        |             |             | sum         | median      | std         | sum        | mean           |  |
| 0  | -                |      | CLORALEX    | jun-22 | CLORO       | TOTAL AUTOS | 0.435       | 0.435       | 0           | 5.788      | 9.255          |  |
| 1  | -                |      | CLOROX      | jun-22 | CLORO       | TOTAL AUTOS | 1.097       | 1.097       | 0           | 16.307     | 14.064         |  |
| 2  | 0757037514016BP1 |      | OXI CLEAN   | may-22 | SAFE BLEACH | TOTAL AUTOS | 0.46        | 0.46        | 0           | 10.209     | 3.194          |  |
| 3  | 1.23E+11         |      | CLORALEX    | 34-22  | CLORO       | TOTAL AUTOS | 0.072       | 0.072       | 0           | 18.88      | 1.309          |  |
| 4  | 19200958714      |      | LYSOL       | 34-22  | SANITIZANTE | TOTAL AUTOS | 2.188       | 2.188       | 0           | 23.792     | 17.934         |  |
| 5  | 3.05E+12         |      | SANYTOL     | may-22 | SAFE BLEACH | TOTAL AUTOS | 4.276       | 4.276       | 0           | 94.262     | 6.188          |  |
| 6  | 3.05E+12         |      | SANYTOL     | may-22 | SANITIZANTE | TOTAL AUTOS | 0.17        | 0.085       | 0.09616652  | 18.104     | 3.5215         |  |
| 7  | 37000018704      |      | TIDE        | 34-22  | SAFE BLEACH | TOTAL AUTOS | 0.811       | 0.811       | 0           | 146.759    | 3.755          |  |
| 8  | 37000213215      |      | TIDE        | 34-22  | SAFE BLEACH | TOTAL AUTOS | 3.507       | 3.507       | 0           | 55.856     | 28.282         |  |
| 9  | 37000830870      |      | TIDE        | 34-22  | SAFE BLEACH | TOTAL AUTOS | 6.539       | 6.539       | 0           | 80.169     | 23.025         |  |
| 10 | 37000889281      |      | TIDE        | 34-22  | SAFE BLEACH | TOTAL AUTOS | 2.547       | 2.547       | 0           | 40.336     | 20.54          |  |
| 11 | 4.01E+12         |      | DR.BECKMAN  | may-22 | CLORO       | TOTAL AUTOS | 86.958      | 17.859      | 35.5937292  | 1648.512   | 15.3156667     |  |
| 12 | 4.01E+12         |      | DR.BECKMAN  | may-22 | PRE LAVADO  | TOTAL AUTOS | 134.198     | 3.673       | 15.6850863  | 3869.604   | 9.69907143     |  |
| 13 | 4.01E+12         |      | DR.BECKMAN  | may-22 | SAFE BLEACH | TOTAL AUTOS | 9.368       | 2.201       | 1.54465336  | 601.386    | 3.93925        |  |
| 14 | 41380309109      |      | OTHERS MAR  | 34-22  | CLORO       | TOTAL AUTOS | 6.774       | 6.774       | 0           | 86.104     | 21.505         |  |
| 15 | 41380309116      |      | OTHERS MAR  | 34-22  | CLORO       | TOTAL AUTOS | 0.008       | 0.008       | 0           | 0.104      | 1.6            |  |
| 16 | 41596020959      |      | ARTIC WHITE | 34-22  | CLORO       | TOTAL AUTOS | 0.997       | 0.997       | 0           | 93.124     | 4.279          |  |
| 17 | 43152007114      |      | CLORALEX    | 34-22  | SAFE BLEACH | TOTAL AUTOS | 0.078       | 0.078       | 0           | 12.953     | 2.167          |  |
| 18 | 44600002033      |      | CLOROX      | 34-22  | CLORO       | TOTAL AUTOS | 0.351       | 0.351       | 0           | 66.053     | 3.311          |  |

Se demuestra a base de esta imagen que todo dato se encuentra en su respectivo lugar o que no hay alguno que se haya malinterpretado ( a excepción de los datos que cada programa lo toma automáticamente )

## 8. Conclusiones

En la realización de este proyecto me pude percatar que la información poco a poco se iba resumiendo cada que se manipulaban los datos, es decir, que esta parte aun siendo de "Limpieza" se filtran ciertos elementos. Estos elementos terminaron siendo más resumidos por los comandos de unión que se fueron utilizando a lo largo del proceso. Dicho resumen de datos permitió que diera una mejor visualización de los datos, al ser un fragmento más corto permitió que varios datos se agruparan con otros para traer un DataFrame final. Éste permitirá generar un grafico o varios que den a entender que es lo que esta ocurriendo, resolviendo varias de las dudas que surgieron por parte de la misma empresa que dio los datos, en este caso Reckitt.

Se puede concluir esta parte del proyecto que se realizaron bastantes limpiezas y filtrados para dar los últimos toques sobre los datos para que estos conservaran su tipo de dato además de su adición por columnas donde incluyeron cálculos relevantes para su próximo manejo